

논문 / 주요연구과제

성균관대학교

전자전기컴퓨터공학과

김하령

- 핵심 역량 / 논문 소개
 - Open-vocabulary 기반 시맨틱 장소 인식 및 환경 모델링 프레임워크
 - Toward Long-Term Memory in Embodied AI: A Knowledge-Grounded 3D Scene Graph Framework
 - DK-SMF: Domain Knowledge-Driven Semantic Modeling Framework for Service Robots
 - LLM-RAG 기반 로봇 Embodiment-aware Affordance 자동 생성 프레임워크
 - Pre-execution Feasibility Checking for Language-Guided Robotic Manipulation via 3D Scene Graph and Object Ontology
 - 시뮬레이터 간 VLA 정책 전이를 위한 성능 갭 정량화 및 효율적 데이터 기반 적응 기법
 - AI Agentic 프레임워크 기반 LLM 로봇 조작 오케스트레이션 시스템
- 진행 중인 연구
 - VLA 기반 산업용 로봇 조작 정책 학습 및 실환경 전이(26.01~)
 - 기술 역량
 - 연구 실적

목차

- 핵심 역량 / 논문 소개
 - Open-vocabulary 기반 시맨틱 장소 인식 및 환경 모델링 프레임워크
 - Toward Long-Term Memory in Embodied AI: A Knowledge-Grounded 3D Scene Graph Framework
 - DK-SMF: Domain Knowledge-Driven Semantic Modeling Framework for Service Robots
 - LLM-RAG 기반 로봇 Embodiment-aware Affordance 자동 생성 프레임워크
 - Pre-execution Feasibility Checking for Language-Guided Robotic Manipulation via 3D Scene Graph and Object Ontology
 - 시뮬레이터 간 VLA 정책 전이를 위한 성능 갭 정량화 및 효율적 데이터 기반 적응 기법
 - AI Agentic 프레임워크 기반 LLM 로봇 조작 오케스트레이션 시스템
- 진행 중인 연구
 - VLA 기반 산업용 로봇 조작 정책 학습 및 실환경 적용(26.01~)
- 기술 역량
- 연구 실적

■ 기술 역량

Programming Language

- Python, C/C++
- ROS 2 (rclcpp·rclpy, Executor·Callback Group, DDS)
- PyTorch, TensorFlow, ONNX (모델 변환·배포)

Tools

- Simulation: NVIDIA Isaac Sim, MuJoCo, Gazebo
- Dev·Debug: RViz, rosbag, Docker, Linux
- 3D Processing: Open3D, PCL
- Knowledge Graph: Neo4j, Cognee, RDF/OWL

Robotics & AI Framework

- Open-vocabulary 인지 (Grounding DINO, SAM, CLIP), VQA, LLM 기반 인지 파이프라인
- 3D Scene Graph 설계 및 Semantic DB(TOSM) 구축
- VLA(π_0) Fine-tuning 및 MuJoCo → Isaac Sim Sim2Sim 적응
- Doosan M1013 Sim2Real 플랫폼 개발 (진행 중)

Hardware & Sensors

- Manipulator: Doosan M-Series (M1013), Universal Robots UR3e
- LiDAR (SICK multiScan, Leica BLK360, Velodyne, Hesai)
- RGB-D-Stereo Camera (Intel RealSense, GMSL2 Camera)
- Multimodal Sensor Fusion (Camera ×4, LiDAR ×2)

Computing & Embedded System

- NVIDIA Jetson (Xavier, Orin), Neosys NRU 시리즈
- Intel NUC, Industrial PC (IPC)
- 분산 SBC 간 ROS 2 통신 병목 분석·최적화

Other

- Knowledge-Grounded Reasoning (LLM + Scene Graph)
- Pre-execution Feasibility Reasoning (물리 제약 기반 판단)
- LLM Agent·RAG 기반 작업 오케스트레이션·Failure Recovery
- Semantic HRI (자연어 지시 → 그래프 기반 제어)

목차

- 핵심 역량 / 논문 소개
 - Open-vocabulary 기반 시맨틱 장소 인식 및 환경 모델링 프레임워크
 - Toward Long-Term Memory in Embodied AI: A Knowledge-Grounded 3D Scene Graph Framework
 - DK-SMF: Domain Knowledge-Driven Semantic Modeling Framework for Service Robots
 - LLM-RAG 기반 로봇 Embodiment-aware Affordance 자동 생성 프레임워크
 - Pre-execution Feasibility Checking for Language-Guided Robotic Manipulation via 3D Scene Graph and Object Ontology
 - 시뮬레이터 간 VLA 정책 전이를 위한 성능 갭 정량화 및 효율적 데이터 기반 적응 기법
 - AI Agentic 프레임워크 기반 LLM 로봇 조작 오케스트레이션 시스템
- 진행 중인 연구
 - VLA 기반 산업용 로봇 조작 정책 학습 및 실환경 적용(26.01~)
 - 기술 역량
 - 연구 실적

연구 실적

■ 논문

- **Haryeong Kim**, Kyeongjin Joo, Gilberto Galvis Giraldo, Sangmin Kim and Taeyong Kuc, "Toward Long-Term Memory in Embodied AI: A Knowledge-Grounded 3D Scene Graph Framework" (*ISIS 2025, 게재 완료*)
- Kyeongjin Joo, Yeseul Jeong, Seungwon Kwon, Minyoung Jeong, **Haryeong Kim** and Taeyong Kuc, "DK-SMF: Domain Knowledge-Driven Semantic Modeling Framework for Service Robots" (*MDPI Electronics, 게재 완료*)
- **Haryeong Kim**, Kyeongjin Joo, Yeseul Jeong, Minyoung Jung, Taeyong Kuc, "Open-vocabulary 기반 시맨틱 장소 인식 및 환경 모델링 프레임워크" (*대한전자공학회 하계논문대회 2025, 게재 완료, 우수학생논문상 수상*)
- **Haryeong Kim**, Kyeongjin Joo, Taeyong Kuc, "LLM-RAG 기반 로봇 Embodiment-aware Affordance 자동 생성 프레임워크" (한국지능정보시스템학회 2025 추계학술대회, 게재 완료)
- **Haryeong Kim**, Taeyong Kuc, "Pre-execution Feasibility Checking for Language-Guided Robotic Manipulation via 3D Scene Graph and Object Ontology" (ICCAS 2026, 게재 확정)
- **Haryeong Kim**, Taeyong Kuc, "시뮬레이터 간 VLA 정책 전이를 위한 성능 갭 정량화 및 효율적 데이터 기반 적응 기법" (대한전자공학회 하계종합학술대회 2026, 게재 완료)
- **Haryeong Kim**, Taeyong Kuc, "AI Agentic 프레임워크 기반 LLM 로봇 조작 오케스트레이션 시스템" (제어로봇시스템학회 학술대회 ICROS 2026, 게재 완료, 우수논문 선정)

■ 학술지(저널)

- Kyeongjin Joo, Yeseul Jeong, Seungwon Kwon, Minyoung Jeong, **Haryeong Kim**, Taeyong Kuc "DK-SMF: Domain Knowledge-Driven Semantic Modeling Framework for Service Robots", **MDPI Electronics** (게재 완료, SCIE 저널)
- Sangmin Kim, Yonghyeon Song, Byeongjun Kim, **Haryeong Kim**, Tae-Yong "From Terrestrial Laser Scans to Queryable Robot Knowledge: A VLM-Verified Framework for Incremental 3D Semantic Modeling", **MDPI, Electronics**(게재 중, SCIE 저널)

■ 프로젝트

- VLA 기반 산업용 로봇 조작 정책 학습 및 실환경 전이(2026.01 ~)

■ 수상

- 대한전자공학회 하계논문대회 2025 - 우수학생논문상 수상 (논문: Open-vocabulary 기반 시맨틱 장소 인식 및 환경 모델링 프레임워크s)



- **핵심 역량 / 논문 소개**
 - Open-vocabulary 기반 시맨틱 장소 인식 및 환경 모델링 프레임워크
 - Toward Long-Term Memory in Embodied AI: A Knowledge-Grounded 3D Scene Graph Framework
 - DK-SMF: Domain Knowledge-Driven Semantic Modeling Framework for Service Robots
 - LLM-RAG 기반 로봇 Embodiment-aware Affordance 자동 생성 프레임워크
 - Pre-execution Feasibility Checking for Language-Guided Robotic Manipulation via 3D Scene Graph and Object Ontology
 - 시뮬레이터 간 VLA 정책 전이를 위한 성능 갭 정량화 및 효율적 데이터 기반 적응 기법
 - AI Agentic 프레임워크 기반 LLM 로봇 조작 오케스트레이션 시스템
- **진행 중인 연구**
 - VLA 기반 산업용 로봇 조작 정책 학습 및 실환경 전이(26.01~)
 - 기술 역량
 - 연구 실적

핵심 역량 / 논문 소개

• 핵심 역량 / 논문

< 활동 내역 상세 >

Open-vocabulary 기반 시맨틱 장소 인식 및 환경 모델링 프레임워크

- **ZSOD(Zero-shot Object Detection)** 기반 객체 검출 및 Semantic DB(객체·관계·속성) 생성
- 객체 리스트를 LLM 프롬프트로 변환 → **장소 의미 추론** 수행
- 추론 결과를 **Scene Graph** 기반 **Semantic Map**(TOSM 스키마 적용)으로 구조화

Toward Long-Term Memory in Embodied AI: A Knowledge-Grounded 3D Scene Graph Framework

- 실세계 Point Cloud 기반 **Scene Graph**(객체·관계·속성) 자동화
- Multi-Attribute Scene Graph를 **Semantic Memory Engine** 저장
- LLM과 연동한 **reasoning** 검증

< 보유 역량 >

- **Open-vocabulary Object Detection** 모델 운용 및 확장 경험
- **LLM** 기반 시맨틱 맵 자동 구축 및 지식 DB 연동 기술
- 시뮬레이터 환경 경험

- **Real-world 3D Scene Graph** 생성 및 처리 능력
- **Semantic Memory Engine + LLM** 추론 파이프라인 구현 경험
- 시뮬레이터·실세계 데이터 통합 실험 주도 경험

핵심 역량 / 논문 소개

• 핵심 역량 / 논문

< 활동 내역 상세 >

DK-SMF: Domain Knowledge-Driven Semantic Modeling Framework

- **Domain Knowledge based place rules**를 적용하여 Scene Graph 보정
- 실제 공장 데이터를 반영한 **Knowledge-Grounded Semantic Map** 구축
- 시뮬레이터 + 실제 데이터 통합 실험으로 **산업 적용성** 검증

LLM-RAG 기반 로봇 Embodiment-aware Affordance 자동 생성 프레임워크

- 기존 SMF의 수동 속성 정의 한계를 발견, **URDF-매뉴얼 입력 기반 Embodiment-aware 자동 생성 파이프라인** 설계·구현
- **RAG 기반 Knowledge Retriever → LLM Prompt Builder → TOSM Validator**로 이어지는 5단계 파이프라인 구축
- 산업·서비스 로봇 4종 대상 실험, 전문가 정의 대비 **의미적 일치율 92~95%** 달성

< 보유 역량 >

- **Domain Knowledge**와 **Scene Graph**를 결합한 Semantic Modeling 경험
- 불완전한 데이터 보정 및 지식 기반 reasoning 수행 능력
- 시장에 널리 쓰이는 **로봇(로봇 청소기)** 핸들링 경험

- **LLM-RAG** 기반 지식 검색 및 **Embodiment-aware** 추론 파이프라인 설계 경험
- **URDF** 구조 분석 및 로봇 물리적 제약 자동 반영 기술
- **TOSM** 스키마 기반 시맨틱 속성 자동 생성 및 검증 경험
- 산업·서비스 로봇 4종의 **URDF** 및 매뉴얼 분석·처리 경험

핵심 역량 / 논문 소개

• 핵심 역량 / 논문

< 활동 내역 상세 >

Pre-execution
Feasibility
Checking for Language-
Guided Robotic
Manipulation
via 3D Scene Graph and
Object Ontology

- RGB-D 스캔에서 SAM → Depth Lifting → CLIP으로 객체별 **TOSM 3-Layer 온톨로지**(Symbolic·Explicit·Implicit) 자동 구축
- **Domain Knowledge DB + GPT-4 Fallback** 하이브리드 속성 추정 → **3D Scene Graph**로 구조화
- 실행 전 **Feasibility Function $F(o)$** (Lift·Grasp·Movable·Reach)를 **Deterministic Rule**로 판정 → 불필요 시도 **37.5 → 10.0%**, 성공률 **62.5 → 85.0%**

시뮬레이터 간
VLA 정책 전이를 위한
성능 갭 정량화 및
효율적 데이터 기반
적응 기법

- MuJoCo에서 **Human Demo 100 ep**로 사전학습 **π_0 VLA 정책 Fine-tuning** (Doosan M1013 Pick & Place)
- 재학습 없이 Isaac Sim으로 이식해 **Zero-shot Sim2Sim** 갭 정량화: 91% → 33% (**-58%p**)
- Isaac Sim Adaptation Data(10·50·100 ep)로 **Action Expert** 중심 **Fine-tuning** → 86% 회복 (**in-domain 대비 94%**)

< 보유 역량 >

- 3D Scene Graph·Object Ontology 기반 **Affordance Reasoning** 설계 경험
- LLM은 속성 추정만, 판정은 규칙으로 분리한 **Hallucination 억제** 구조 설계
- **Isaac Sim** 모바일 매니퓰레이터(UR5) 기반 **실행 전 검증 실험** 설계·수행

- **π_0 기반 VLA 정책** Fine-tuning 및 Rollout 평가 경험
- **MuJoCo·Isaac Sim** 이중 물리엔진 환경 구축 및 **도메인 갭 분석** 역량
- 조건별 50회 rollout 기반 **데이터 규모-성능 회복 곡선** 정량 실험 설계

핵심 역량 / 논문 소개

• 핵심 역량 / 논문

AI Agentic 프레임워크 기반 LLM 로봇 조작 오케스트레이션 시스템

< 활동 내역 상세 >

- AI Agentic 프레임워크 **OpenClaw**(Jetson) 기반, LLM은 초기 **Workflow 1회** 생성에만 사용하는 오케스트레이션 구조 설계
- Step별 실행 결과를 **JSON**으로 모니터링, reason 필드로 **Perception·Manipulation·Verification** 실패 자동 분류 후 **Rule-based Recovery** 적용
- LLM 재호출 방식 대비 성공률 **76.0 → 88.0%**, 복구 지연 **5.2s → 0.4s**, 추가 LLM 호출 **0회**

< 보유 역량 >

- **AI Agent 기반 로봇 작업 오케스트레이션**(Planning-Execution-Monitoring-Recovery) 설계 경험
- **Failure Classification-Recovery** 전략 설계를 통한 시스템 신뢰성 향상
- **Jetson-Local PC 원격 실행** 구조 구현 및 LLM 호출 비용·지연 최적화

- 핵심 역량 / 논문 소개
 - Open-vocabulary 기반 시맨틱 장소 인식 및 환경 모델링 프레임워크
 - Toward Long-Term Memory in Embodied AI: A Knowledge-Grounded 3D Scene Graph Framework
 - DK-SMF: Domain Knowledge-Driven Semantic Modeling Framework for Service Robots
 - LLM-RAG 기반 로봇 Embodiment-aware Affordance 자동 생성 프레임워크
 - Pre-execution Feasibility Checking for Language-Guided Robotic Manipulation via 3D Scene Graph and Object Ontology
 - 시뮬레이터 간 VLA 정책 전이를 위한 성능 갭 정량화 및 효율적 데이터 기반 적응 기법
 - AI Agentic 프레임워크 기반 LLM 로봇 조작 오케스트레이션 시스템
- 진행 중인 연구
 - VLA 기반 산업용 로봇 조작 정책 학습 및 실환경 전이(26.01~)
 - 기술 역량
 - 연구 실적

Open-vocabulary 기반 시맨틱 장소 인식 및 환경 모델링 프레임워크

■ 의미 기반 장소 추론 시스템 (Semantic Place Inference System, 장소 인식용 시맨틱 DB 자동 구축 프레임워크) 개요

- ZSOD을 활용해, 사전 학습 없이 다양한 객체 탐지 및 입력 정보 생성
- 인식된 객체 리스트를 LLM에 프롬프트로 변환 → 장소 의미 추론 및 자동 Semantic DB 생성
- 추론된 결과를 Multi-Attribute 형식으로 구조화 → Semantic DB(TOSM 스키마 기반)에 저장
- 새로운 환경에서도 일반화 가능 → 제조 / 서비스 로봇의 비정형 환경 대응력 향상

■ 주요 Method

• 객체 중심 장면 이해(Object-Centric Scene Understanding)


- 새로운 환경에서도 빠른 장소 인식 지원

• LLM 기반 장소 추론(Place Inference using LLM)

- 로봇의 상황 판단 및 미션 계획으로 확장 가능

• TOSM Schema based Semantic DB 설계

- 산업 환경 데이터와 결합 가능성 확보



<Figure 1. Semantic Place Inference System Flowchart>

▪ 객체 중심 장면 이해(Object-centric Scene Understanding)

- ZSOD 기반으로 사전 학습된 라벨 없이도 다양한 객체를 인식 → 추가 데이터 수집/학습 없이도 새로운 제조·서비스 환경에 적용 가능
- 인식 결과에서 객체의 **class**, **위치**, **pose** 정보를 추출하여 경로 계획에 활용
- **Multi-view Image** 활용으로 **occlusion** 문제를 최소화 → 복잡한 작업 공간에서도 인식 안정성 확보




<Figure 2. ZSOD-based Object Detection Results>

Open-vocabulary 기반 시맨틱 장소 인식 및 환경 모델링 프레임워크


■ LLM기반 장소 추론(Place Inference using LLM)

- 인식된 객체 리스트를 기반으로 장소 개념을 추론하는 **in-context learning** 적용
- **Few-shot prompting** 활용 → 소량의 예시만으로도 새로운 환경에 일반화 가능
- 장소 명시가 없어도 LLM이 문맥 기반 **reasoning**을 수행 → 주방, 거실, 작업대 등 장소 구분 가능



<Figure 3. Place Inference Flow Chart>


Element	Content
Input Sentence	"Are there refrigerator and gasstove in kitchen?"
Output	{"places": 'kitchen', "objects": ['refrigerator', 'gasstove']}




<Figure 4. Structured Prompt>

■ Semantic DB 설계

- 추론된 객체 및 장소 정보를 **Semantic DB (TOSM 스키마 적용)**에 저장
- Symbolic**(객체 ID/이름) - **Explicit**(위치, 크기, 센서 정보) - **Implicit**(목적, 사용성 등) 모델로 객체·장소 간 관계를 표현
- 계층적 장소 구조와 객체 속성을 포함하여 **시맨틱 기반 경로 탐색 및 작업 계획**에 활용



<Figure 5. Triplet Ontological Semantic Model>




<Figure 6 TOSM-based database for experiments>

Open-vocabulary 기반 시맨틱 장소 인식 및 환경 모델링 프레임워크

■ 실험 환경

- 환경 유형: 실내 가정 공간
- 시뮬레이터: NVIDIA Isaac Sim
- 공간 구성: 거실(Living Room), 주방(Kitchen), 침실(Bed Room), 욕실(Bath Room), 복도(Hallway), 식사 공간(Dining Room)
- 센서 구성: Stereo RGB-D Camera
- 수집 데이터: RGB Image, Depth Map, 3D Pose, Object Label



<Figure 7. Nova Carter>



<Figure 8. Test Environment>

▪ Few-shot 기반 LLM 장소 추론 성능

- 사전 학습 없이도 시맨틱 객체 정보만으로 장소 개념 추론 성공
- 평균 정확도 98.3%, 일반화 성공률 최대 94% 달성→ 새로운 공간에서도 안정적인 추론 가능
- 평균 추론 속도 669ms→ 로봇 실시간 경로 탐색 및 내비게이션 적용 가능

▪ 실험 결과 요약

- Kitchen: 정확도 100%→ 작업 공간 내 고정된 설비/장치 인식에 최적
- Living Room: 정확도 98%→ 복잡한 가구 배치 환경에서도 신뢰성 확보
- Bed Room: 정확도 97%→ 변동성이 높은 환경에서도 일반화 가능

▪ 산업 적용 의미

- LG 서비스 로봇: 새로운 주거 공간에 투입 시, 추가 학습 없이도 즉시 공간 분류 가능
- LG 스마트팩토리 로봇: 생산 라인 변경 시에도 빠르게 작업 구역을 재인식 → 재설정 비용 절감 및 효율 극대화

Place	Total Samples	Accuracy(%)	Avg. Inference Time(ms)	Rule Violations	Generalization Success Rate(%)
Kitchen	100	100.0%	643.98	0	100.0%
Living Room	100	98.0%	712.54	2	95.2%
Bed Room	100	97.0%	651.73	1	94.5%

<Table 1. Experiment Results>

- **핵심 역량 / 논문 소개**
 - Open-vocabulary 기반 시맨틱 장소 인식 및 환경 모델링 프레임워크
 - **Toward Long-Term Memory in Embodied AI: A Knowledge-Grounded 3D Scene Graph Framework**
 - DK-SMF: Domain Knowledge-Driven Semantic Modeling Framework for Service Robots
 - LLM-RAG 기반 로봇 Embodiment-aware Affordance 자동 생성 프레임워크
 - Pre-execution Feasibility Checking for Language-Guided Robotic Manipulation via 3D Scene Graph and Object Ontology
 - 시뮬레이터 간 VLA 정책 전이를 위한 성능 갭 정량화 및 효율적 데이터 기반 적응 기법
 - AI Agentic 프레임워크 기반 LLM 로봇 조작 오케스트레이션 시스템
- **진행 중인 연구**
 - VLA 기반 산업용 로봇 조작 정책 학습 및 실환경 전이(26.01~)
 - 기술 역량
 - 연구 실적


Toward Long-Term Memory in Embodied AI

Knowledge-Grounded 3D Scene Graph 개요

- 이전 연구: 기존 ZSOD + LLM 연구를 실세계 3D point cloud로 확장, 신뢰성 있는 인지·추론 달성 목표
- 본 연구: Embodied AI의 장기 메모리 엔진으로 작동. LLM을 구조화된 지식 그래프와 연동해 잘못된 판단 최소화, 사실 기반 reasoning 강화

주요 Method

- Instance Segmentation using Geo-Prompted SAM
- Multi-Attribute Extraction
- Knowledge-Attribute Extraction




<Figure 9. Overview of Long-Term Memory in Embodied AI>

Toward Long-Term Memory in Embodied AI

▪ Instance Segmentation using Geo-prompted SAM

- 기존 Method(Poin-SAM) 한계: FPS 기반 uniform sampling만 사용→구조적 정보 부족, 단일 객체만 세분화 가능
- Improvement 1: RANSAC 기반 평면 제거 + Clustering 적용→배경 제거 후 다중 객체 분리 가능
- Improvement 2: 각 cluster 중심을 Object-aware prompt로 활용→Multi-object segmentation 가능
- Improvement 3: Multi-view projection 기법 적용→occlusion 상황에서도 세분화 정확도 향상



Toward Long-Term Memory in Embodied AI

Experiment Setting


구분	내용
환경 유형	cafeteria, office, corridor, kitchen (LiDAR Scanner 기반 수집)
평가 프로토콜	비교 대상: Knowledge-Grounded Framework vs LLM-only (GPT-4)
Query 유형	• Symbolic: 객체 존재 유무 • Explicit: 속성 인식 • Implicit: 객체 간 관계 추론 • Scene-level: 장소 추론
주요 결과	• Symbolic: baseline은 hallucination 7회 발생 • Explicit & Implicit: 속성·관계 추론에서 fabrication 없음 • Scene-level: 쿼리 4/5 정답(baseline은 1/5) • Knowledge Grounding → 환각 감소 + 사실 기반 응답 강화

Toward Long-Term Memory in Embodied AI

Experiment Result

- Symbolic: 정확도 90% (18/20), baseline은 hallucination 7회 발생
- Explicit & Implicit: 속성·관계 추론에서 fabrication 없음
- Scene-level: 장소 추론 정확도 80% (4/5), baseline 20% (1/5)
- Knowledge-Grounded: 환각 감소 + 사실 기반 응답 강화

Knowledge-Grounded 3D Scene Graph Framework:
객체 단위 분할 + 속성 기반 그래프
➡ 사실 기반 reasoning, 안정적 HRI



<Figure 12 (a): The Knowledge-Grounded Setting >

<Figure 12 (b): The baseline>

<Figure 12. Comparison of query answering with and without structured grounding: LLM 단독은 환각 발생, 본 연구는 Scene Graph + Neo4j 기반으로 사실에 근거한 응답 생성>

- 핵심 역량 / 논문 소개
 - Open-vocabulary 기반 시맨틱 장소 인식 및 환경 모델링 프레임워크
 - Toward Long-Term Memory in Embodied AI: A Knowledge-Grounded 3D Scene Graph Framework
 - **DK-SMF: Domain Knowledge-Driven Semantic Modeling Framework for Service Robots**
 - LLM-RAG 기반 로봇 Embodiment-aware Affordance 자동 생성 프레임워크
 - Pre-execution Feasibility Checking for Language-Guided Robotic Manipulation via 3D Scene Graph and Object Ontology
 - 시뮬레이터 간 VLA 정책 전이를 위한 성능 갭 정량화 및 효율적 데이터 기반 적응 기법
 - AI Agentic 프레임워크 기반 LLM 로봇 조작 오케스트레이션 시스템
- 진행 중인 연구
 - VLA 기반 산업용 로봇 조작 정책 학습 및 실환경 전이(26.01~)
 - 기술 역량
 - 연구 실적

DK-SMF: Domain Knowledge-Driven Semantic Modeling Framework

DK-SMF: Domain Knowledge-Driven Semantic Modeling Framework


- 이전 연구: 3D 포인트 클라우드 → Only 그래프화 LLM 질의 한계
- 본 연구: 실제 서비스 로봇 업로드 & 활용 가능한 프레임워크 제안
- Domain Knowledge + ZSOD + VQA + LLM 기반 자동 환경 모델링

주요 Method

- 자율 탐사 + 객체 검출 → Zero-shot 기반 객체 의미 추출

My
Contribution

- 장소 추론 → Object List + Domain Knowledge → LLM
- Semantic DB → RDF/OWL 기반, 다계층 시맨틱 맵 구축




<Figure 13. DK-SMF Framework Architecture>

DK-SMF: Domain Knowledge-Driven Semantic Modeling Framework

장소 추론(LLM 기반 공간 의미 이해)

- SLAM 기반 2D map → SLIC segmentation으로 장소 후보 생성
- Object List + Domain Knowledge DB → LLM 추론
- 장소 class & purpose 속성 도출(85% Accuracy)
- KeyObject/PrimeObject 지정으로 장소 인식 안정화
- 의의: 객체 인식 → 공간 의미 이해 확장 → 서비스 로봇 자율 적응 기반 확보



<Figure 14. Overview of Place Semantic Information Extraction>

Object List + Domain Knowledge → LLM Inference

- 장소 class & purpose 속성 자동 도출 (85% 정확도)
- KeyObject / PrimeObject 지정 → 안정적 장소 인식
- 의의: 객체 인식 → 공간 의미 이해 확장, 로봇의 자율 적응 기반 확보

DK-SMF: Domain Knowledge-Driven Semantic Modeling Framework

■ 실험 환경

• 환경 유형:

- Simulation: 가정집 공간(Living Room, Kitchen, Bed Room, Bath Room, Dining Room, Hallway)
- Real-world: 복도 환경

• 시뮬레이터:

- NVIDIA Isaac Sim

• 센서 구성:

- Stereo RGB-D Camera
- 2D/3D LiDAR

• 수집 데이터:


- RGB Image
- Depth Map
- 3D Pose
- Object Label

• 평가 지표:

- Object Semantic Accuracy
- Place Semantic Accuracy
- DB Consistency



<Figure 15. Simulation Environment>



<Figure 16. Real-world Environment>

- 핵심 역량 / 논문 소개

- Open-vocabulary 기반 시맨틱 장소 인식 및 환경 모델링 프레임워크
- Toward Long-Term Memory in Embodied AI: A Knowledge-Grounded 3D Scene Graph Framework
- DK-SMF: Domain Knowledge-Driven Semantic Modeling Framework for Service Robots
- **LLM-RAG 기반 로봇 Embodiment-aware Affordance 자동 생성 프레임워크**
- Pre-execution Feasibility Checking for Language-Guided Robotic Manipulation via 3D Scene Graph and Object Ontology
- 시뮬레이터 간 VLA 정책 전이를 위한 성능 갭 정량화 및 효율적 데이터 기반 적응 기법
- AI Agentic 프레임워크 기반 LLM 로봇 조작 오케스트레이션 시스템

- 진행 중인 연구


- VLA 기반 산업용 로봇 조작 정책 학습 및 실환경 전이(26.01~)

- 기술 역량

- 연구 실적

LLM-RAG 기반 로봇 Embodiment-aware Affordance 자동 생성 프레임워크

<Figure 19. Architecture >



■ LLM-RAG 기반 로봇 Embodiment aware Affordance 자동 생성 프레임워크개요

- URDF + 사용자 매뉴얼 기반 실제 구조/기능 정보 자동 수집
- Knowledge Retriever:
 - URDF·매뉴얼에서 실행 가능성을 나타내는 핵심 정보를 추출하여, LLM의 추론을 지원하는 semantic context를 생성
- LLM Prompt Builder:
 - 로봇 Embodiment 정보를 반영한 최적의 LLM 프롬프트 생성
- TOSM Validator:
 - 생성된 affordance를 TOSM schema로 정리


■ 주요 Method

- URDF·매뉴얼 기반 구조·기능 정보 추출
- LLM Prompt Builder & Embodiment-aware Reasoner
- TOSM Validator

LLM-RAG 기반 로봇 Embodiment-aware Affordance 자동 생성 프레임워크

▪ URDF·매뉴얼 기반 구조·기능 정보 추출


- URDF + 사용자 매뉴얼로부터 로봇의 구조·기능 정보를 자동 추출
 - Link/Joint/Sensor/제원/주의사항 등 핵심 요소 정리
- **Knowledge Retriever RAG** 기반으로, 추출된 정보를 Context 단위로 정규화하고 의미적 엔티티로 재조직함
- 정규화된 구조·기능 지식은 이후 LLM 추론 단계에서 Affordance 후보 생성의 기반 데이터로 활용



LLM-RAG 기반 로봇 Embodiment-aware Affordance 자동 생성 프레임워크

■ LLM Prompt Builder & Embodiment-aware Reasoner

- ICL 기반 LLM Prompt Builder가 구조·센서·Spec·제약 정보와 Semantic Example을 결합해 **Embodiment-aware reasoning prompt** 생성
- 유사 구조 로봇의 Example를 포함하여 LLM의 **affordance** 추론 정확도를 향상
- LLM이 논리 규칙 기반으로 수행 가능한 기능만 남기도록 최종 affordance 후보 산출




<Figure 21. Embodiment-aware LLM Prompt 구성 파이프라인>

LLM-RAG 기반 로봇 Embodiment-aware Affordance 자동 생성 프레임워크

▪ TOSM Validator

- LLM이 생성한 affordance-semantic 속성을 도메인 지식과 실제 로봇 구조 기반으로 정제하여 **신뢰도 높은 TOSM JSON**을 생성
- **논리적 일관성 검사**로 속성 간 모순을 제거하고, DK-SMF Ontology 기반 규칙 검사를 통해 **구조적으로 불가능한 기능을 자동 필터링**
- **Embodiment 적합성 검사**로 로봇 형태·구동 방식·센서 구성에 맞지 않는 affordance를 배제
- TOSM 스키마 유효성 검사를 통해 데이터 구조와 타입을 검증하고 **최종 semantic 데이터를 DB에 저장하여 재사용 가능 자원으로 활용**




<Figure 5. Triplet Ontological Semantic Model>

LLM-RAG 기반 로봇 Embodiment-aware Affordance 자동 생성 프레임워크

■ 실험결과

- 로봇별 Sensor·Affordance·Usage Purpose·Additional Semantic 속성을 **JSON 형태로 자동 생성한 결과**
- 방역 로봇(ADAM21): **UV 조사·공기청정·소독 등 도메인 특화 affordance 자동 추출**
- 휴머노이드(G1): **29 DoF 복잡한 관절 구조·냉각 시스템까지 정확히 반영**

<Figure 22. 방역로봇(ADAM21) 생성 결과>



<Figure 23. 휴머노이드(G1) 생성 결과>




- 핵심 역량 / 논문 소개
 - Open-vocabulary 기반 시맨틱 장소 인식 및 환경 모델링 프레임워크
 - Toward Long-Term Memory in Embodied AI: A Knowledge-Grounded 3D Scene Graph Framework
 - DK-SMF: Domain Knowledge-Driven Semantic Modeling Framework for Service Robots
 - LLM-RAG 기반 로봇 Embodiment-aware Affordance 자동 생성 프레임워크
 - **Pre-execution Feasibility Checking for Language-Guided Robotic Manipulation via 3D Scene Graph and Object Ontology**
 - 시뮬레이터 간 VLA 정책 전이를 위한 성능 갭 정량화 및 효율적 데이터 기반 적응 기법
 - AI Agentic 프레임워크 기반 LLM 로봇 조작 오케스트레이션 시스템
- 진행 중인 연구
 - VLA 기반 산업용 로봇 조작 정책 학습 및 실환경 전이(26.01~)
 - 기술 역량
 - 연구 실적

Pre-execution Feasibility Checking for Language-Guided Robotic Manipulation


Pre-execution Feasibility Checking 개요

- 기존 연구: **geometry** 기반 **grasp planning**은 point cloud-depth 정보만 사용 → weight, fixedness 등 **semantic 속성 미반영**, 실행 후 실패 반복
- 본 연구: **3D Scene Graph + Object Ontology**를 결합해 명령 실행 이전에 수행 가능 여부(affordance)를 판정
- 설계 원칙: **LLM**은 **primitive attribute 추정**과 **target grounding**만 담당, 모든 predicate는 **deterministic decision rule**로 계산 → hallucination 차단



주요 Method


- Object Ontology Extraction (TOSM 3-Layer)**
- 3D Scene Graph Construction (Neo4j)**
- Pre-execution Feasibility Function $F(o)$**
- Condition-specific Feedback & 대체 객체 질의**



<Figure 1. Overall Architecture of the Proposed Reasoning Framework>

• Object Ontology Extraction (TOSM 3-Layer Ontology)

- Visual Pipeline: **SAM** instance segmentation → **Depth Lifting** → **Multi-view Merging** → **CLIP** 기반 category 할당
- **Symbolic**(name, category) / **Explicit**(3D position, min bounding box) / **Implicit**(weight, is_fixed, purpose) 3계층 구조화
- Spatial Relation Extraction: LLM으로 6종 관계 triplet 생성 → **category별 scale** 차이를 **threshold** 튜닝 없이 처리
- Room-aware Hybrid 추론: **Domain Knowledge DB** 우선 조회 → 미등록 category는 **GPT-4 fallback** (category·room type·role·robot spec 포함 structured prompt)
- 출력: 객체별 3계층 ontology를 **단일 JSON** 구조로 직렬화 → Scene Graph node 속성으로 사용




<Figure 2. Object Ontology Extraction Pipeline>

3D Scene Graph Construction

- 그래프 정의 $G = (V, E)$ — node: 객체 instance + 전체 TOSM 속성 / edge: **directed spatial relation**
- 관계 유형 6종: **isNextTo**, **isAboveOf**, **isBelowOf**, **isOnTopOf**, **isInFrontOf**, **isBehindOf**
- Semantic type별 node 분류: furniture(green), support/fixture(yellow), small/decor(pink), wall/opening/device(blue)
- **Neo4j** 저장 → **Cypher** 질의 기반 고속 검색으로 feasibility 평가 단계에 속성 제공
- 동일 category 다중 instance의 **language-conditioned disambiguation** 가능 (예: "the cup on the table")



(a) Living Room



(b) Scene Graph

<Figure 3. 3D Scene Graph Constructed from a Living Room Scene in Isaac Sim>

Pre-execution Feasibility Check

- $F(o) = \text{isLiftable}(o) \wedge \text{isGraspable}(o) \wedge \text{isMovable}(o) \wedge \text{isReachable}(o)$
- **isLiftable** : $w + \delta \leq W_{\max}$ ($W_{\max} = 3.0 \text{ kg}$) — 추정 무게 + 안전 여유
- **isGraspable** : $d_{\min} \leq b \leq d_{\max}$ ($d_{\max} = W_{\text{gripper}} = 0.08 \text{ m}$) — point cloud 최소 bounding 치수
- **isMovable** : $\neg \text{is_fixed}$ — Implicit 속성에서 직접 도출, LLM이 술어를 생성하지 않음
- **isReachable** : $\text{FK}(q) = p_o$ 를 만족하는 q 존재 여부 — IK solver로 검증
- 첫 실패 시 **short-circuit** $\rightarrow F(o) = 0$ 과 **condition-specific feedback** 반환
- 동일 purpose를 갖고 $F(o) = 1$ 인 대체 객체를 **Scene Graph**에서 질의 $\rightarrow$ 상위 planner에 전달

Algorithm 1 Pre-execution Feasibility Check

Require: Object o with attributes $\{\text{cat}, p, \text{is_fixed}\}$ retrieved from Scene Graph G (Neo4j); Domain Knowledge DB D_KB ; payload limit $W_{\max}$; gripper opening width W_{gripper} ; workspace $W \subset \mathbb{R}^3$; point cloud $PC(o)$


Ensure: Feasibility decision $F(o) \in \{0,1\}$ and feedback message m

```
1  Retrieve cat, p, is_fixed from Scene Graph G
2  ▷ Step 1: Lift feasibility ( $w \leq W_{\max}$ )
3  if cat  $\in D\_KB$  then
4       $w \leftarrow D\_KB.\text{lookup}(\text{cat})$            ▷ category-level prior
5  else
6       $w \leftarrow \text{GPT-4}.\text{estimate}(\text{cat})$      ▷ commonsense fallback (unseen)
7  end if
8  if  $w > W_{\max}$  then
9      return  $F(o) = 0, m \leftarrow \text{"weight " + } w + \text{" kg exceeds payload " + } W_{\max}$ 
10 end if
11 ▷ Step 2: Grasp feasibility ( $b \leq W_{\text{gripper}}$ )
12  $b \leftarrow \text{PointCloud}.\text{getMinBoundingDim}(PC(o))$ 
13 if  $b > W_{\text{gripper}}$  then
14     return  $F(o) = 0, m \leftarrow \text{"min-dim " + } b + \text{" m exceeds gripper " + } W_{\text{gripper}}$ 
15 end if
16 ▷ Step 3: Movability ( $\neg \text{is\_fixed}$ )
17 if is_fixed = True then
18     return  $F(o) = 0, m \leftarrow \text{"object is fixed to the environment"}$ 
19 end if
20 ▷ Step 4: Reachability ( $\exists q: \text{FK}(q) = p$ )
21  $q \leftarrow \text{IKSolver}.\text{solve}(p)$ 
22 if  $q = \emptyset$  then
23     return  $F(o) = 0, m \leftarrow \text{"no IK solution for target pose " + } p$ 
24 end if
25 return  $F(o) = 1, \text{Execute}(\text{Approach} \rightarrow \text{Grasp} \rightarrow \text{Lift} \rightarrow \text{Place})$ 
```

<Algorithm 1. Pre-execution Feasibility Check>

실험 환경

- 시뮬레이터: **NVIDIA Isaac Sim** (고정밀 물리 시뮬레이션)
- 평가 Scene: 아파트 레이아웃 내 **Living Room / Kitchen / Bedroom** 3개 구역
- 로봇 플랫폼: **Wheeled Mobile Manipulator + UR5 6-DOF Arm**
- 로봇 사양: **$W_{\max} = 3.0 \text{ kg}$** (payload), **$W_{\text{gripper}} = 0.08 \text{ m}$** (최대 개폐 폭)
- Domain Knowledge DB: **30개 object category** 등록 (평균 weight, fixedness, functional purpose 주석)
- 명령 셋: **자연어 명령 40개** — Feasible 25 / Infeasible 15, Known 24 / Unknown 16 (**orthogonal 설계**)
- 평가 지표: Task Success Rate, Unnecessary Attempts, Feasibility Accuracy, Liftability Accuracy



<Figure 4. Experimental Environment in NVIDIA Isaac Sim>

실험 결과

System-level Effectiveness of F(o)

- Task Success Rate: **62.5% → 85.0%**
- Unnecessary Attempts: **37.5% → 10.0%** (infeasible 15건 중 11건 사전 차단)
- Feasibility Accuracy: **87.5% (35/40)**

Hybrid Attribute Estimation (Ablation)

- Known category: 91.7% (22/24) — 동일 DB lookup으로 두 방식 동일
- Unknown category: **56.3% → 87.5%** — GPT-4 fallback 효과
- Overall Liftability Accuracy: **77.5% → 90.0%**

Failure Analysis

- 오분류 5건 중 4건이 weight estimation, 1건은 isGraspable false positive (apple의 곡면)
- 모든 오류가 속성 추정 단계에서 발생 → 속성 추정과 predicate 평가를 분리한 설계의 타당성 입증

Method	Task Success Rate ¹	Unnecessary Attempts ²	Feasibility Accuracy ³
Geometry only	60.0% (24/40)	37.5% (15/40)	—
Ours	85.0% (34/40)	10.0% (4/40)	87.5% (35/40)

<Table 1. Comparison with Geometry-only Baseline>

Method	Known ⁴	Unknown ⁵	Overall Accuracy ⁶
DB only	91.7% (22/24)	56.3% (9/16)	77.5% (31/40)
DB + GPT-4(no room)	91.7% (22/24)	68.8% (11/16)	82.5% (33/40)
DB + GPT-4 (room-aware)	91.7% (22/24)	87.5% (14/16)	90.0% (36/40)


<Table 2. Ablation on Liftability Prediction Accuracy>

	Actual Feasible	Actual Infeasible
Predicted F(o)=1	TP = 24	FP = 4
Predicted F(o)=0	FN = 1	TN = 11

<Table 3. Detailed Analysis of Misclassified Feasibility Predictions>

Qualitative Example & Conclusion

- "Pick up the cup on the table" → 4개 predicate 모두 True, $F(o) = 1 \rightarrow$ 실행
- "Move the sofa" / "Move the bed" → 추정 무게가 payload 초과 → $isLiftable = False$, $F(o) = 0$
- Feedback: "Try moving a pillow instead" — 실패 원인과 대체 객체를 함께 제시하는 해석 가능한 피드백



Pre-execution Feasibility Checking:
Ontology 기반 속성 추정 + 규칙 기반 술어 판정
→ 불필요 실행 37.5% → 10.0%
→ 성공률 62.5% → 85.0%

<Figure 5. Qualitative Examples of the Pre-execution Feasibility Check>

- **핵심 역량 / 논문 소개**

- Open-vocabulary 기반 시맨틱 장소 인식 및 환경 모델링 프레임워크
- Toward Long-Term Memory in Embodied AI: A Knowledge-Grounded 3D Scene Graph Framework
- DK-SMF: Domain Knowledge-Driven Semantic Modeling Framework for Service Robots
- LLM-RAG 기반 로봇 Embodiment-aware Affordance 자동 생성 프레임워크
- Pre-execution Feasibility Checking for Language-Guided Robotic Manipulation via 3D Scene Graph and Object Ontology
- **시뮬레이터 간 VLA 정책 전이를 위한 성능 갭 정량화 및 효율적 데이터 기반 적응 기법**
- AI Agentic 프레임워크 기반 LLM 로봇 조작 오케스트레이션 시스템

- **진행 중인 연구**


- VLA 기반 산업용 로봇 조작 정책 학습 및 실환경 전이(26.01~)

- 기술 역량


- 연구 실적

• Sim2Sim VLA 정책 전이 연구 개요

- 배경: 시뮬레이터 기반 학습은 실제 로봇 데이터 수집 비용과 안전 문제를 줄이지만, 시뮬레이터별 물리·렌더링 모델링 차이로 정책 전이가 어려움
- 한계: 기존 Sim2Sim 연구는 **locomotion** 태스크 중심 → VLA 기반 manipulation 정책의 전이 성능 저하 폭과 회복 가능성은 정량 분석 부재
- 본 연구: MuJoCo 학습 π_0 기반 VLA 정책을 재학습 없이 Isaac Sim으로 이식해 **Sim2Sim Gap**을 정량화하고, 소량 데이터 적응으로 회복 가능성 검증



Policy Transfer
Without training



• 주요 Method

- Real-to-Sim 환경 재구성 (Articulated USD)
- MuJoCo 기반 Coarse Policy 학습 (π_0 fine-tuning)
- Isaac Sim Zero-shot Rollout — Gap 측정
- 소량 Adaptation Data 기반 Post-Training

<Figure 1. Problem Definition — Sim2Sim Transfer Gap of a VLA Policy>

Method — Coarse-to-Fine Sim2Sim 적응 파이프라인


- ① **Real-to-Sim Transfer** : 실제 작업 공간을 Articulated USD로 재구성해 target simulator(Isaac Sim) 환경 구축
- ② **MuJoCo 기반 Coarse Policy 학습** : 사전학습 VLM(SigLIP+Gemma) 기반 π_0 정책을 human demonstration 100 episode(태스크별 50)로 fine-tuning
- ③ **Isaac Sim Post-Training Rollout** : 학습 정책을 재학습 없이 이식해 zero-shot 성능 측정 → 이후 10 / 50 / 100 episode adaptation data로 추가 fine-tuning
- Coarse-to-Fine 전략** : source에서 기본 조작 능력 학습 → target에서는 전체 재학습이 아닌 소량 데이터 적응만 수행 → 단계별 성능 기여도를 독립 측정 가능하도록 설계
- 환경 구성: Doosan M1013 6-DoF 매니퓰레이터, 대상 객체 cracker box · sugar box · plastic bin, 전면 고정 RGB 카메라 1대
- 언어 명령 2종으로 동일 환경 내 목표 객체 선택 능력까지 학습되도록 태스크 구성



<Figure 2. Coarse-to-Fine Sim2Sim Adaptation Pipeline>

· 실험 환경


- Source simulator: **MuJoCo** — soft-contact 기반 constraint solver
- Target simulator: **Isaac Sim** — NVIDIA PhysX 기반 rigid-body 물리 엔진
- 도메인 갭 요인: 접촉 모델 · 마찰 표현 · 물리 solver · 렌더링 파이프라인 차이 → 파지 안정성과 미끄러짐 거동에 영향
- 로봇 및 객체: Doosan M1013 6-DoF 매니퓰레이터 / cracker box · sugar box · plastic bin
- 태스크: 언어 명령에 따라 대상 객체를 선택해 plastic bin에 넣는 **pick-and-place**
- 데이터: MuJoCo human demonstration **총 100 episode**(명령별 50) 학습 / Isaac Sim **10 · 50 · 100 episode** 3개 적응 조건
- 평가 지표: Task Success Rate (객체별 및 전체 평균)




<Figure 3. Source and Target Simulation Environments>

실험 결과 (1) — Zero-shot Sim2Sim Transfer Gap

- MuJoCo in-domain 성공률 91% → Isaac Sim zero-shot 이식 시 33%로 감소 (약 58 %p 하락)
- 객체별 저하 폭 상이: cracker box 92 → 35%, sugar box 90 → 29% → 객체 형상·마찰 특성에 따라 파지 안정성과 배치 성공률이 다르게 영향받음
- VLA 정책은 시각 입력·언어 명령·로봇 상태를 함께 처리하므로 물리 차이와 렌더링 차이가 중첩되어 일반 저수준 제어 정책보다 복합적인 도메인 갭에 노출




<Figure 4. Zero-shot Transfer Gap>



<Figure 5. Object-wise Performance Degradation>

· 실험 결과 (2) — Data-efficient Adaptation

- Isaac Sim adaptation data 규모에 따른 회복: 10 ep 54% → 50 ep 74% → 100 ep 86%
- 100 episode만으로 MuJoCo in-domain baseline(91%)의 약 94% 수준까지 회복
- 객체별 회복 추이(cracker / sugar): 10 ep 56 / 52% → 50 ep 76 / 72% → 100 ep 88 / 84%
- 10 → 50 ep 구간 20 %p 향상, 50 → 100 ep 구간 12 %p 향상 → 초기 적응 데이터의 기여가 크고 이후 **diminishing return** 경향
- 의의: 시뮬레이터 교체 시 성능 저하를 **사전 평가**하고, target simulator에서 요구되는 적응 데이터 규모의 경험적 기준을 제시



<Figure 6. Adaptation Recovery Curve>

Zero-shot 전이 -58 %p 성능 저하
→ 100 episode 적응으로 baseline의 94% 회복
→ 데이터 효율적 Sim2Sim 적응 가능성 입증

- **핵심 역량 / 논문 소개**

- Open-vocabulary 기반 시맨틱 장소 인식 및 환경 모델링 프레임워크
- Toward Long-Term Memory in Embodied AI: A Knowledge-Grounded 3D Scene Graph Framework
- DK-SMF: Domain Knowledge-Driven Semantic Modeling Framework for Service Robots
- LLM-RAG 기반 로봇 Embodiment-aware Affordance 자동 생성 프레임워크
- Pre-execution Feasibility Checking for Language-Guided Robotic Manipulation via 3D Scene Graph and Object Ontology
- 시뮬레이터 간 VLA 정책 전이를 위한 성능 갭 정량화 및 효율적 데이터 기반 적응 기법
- **AI Agentic 프레임워크 기반 LLM 로봇 조작 오케스트레이션 시스템**

- **진행 중인 연구**

- VLA 기반 산업용 로봇 조작 정책 학습 및 실환경 전이(26.01~)

- **기술 역량**


- **연구 실적**

연구 개요

- 배경: LLM 기반 로봇 조작 시스템은 자연어 명령을 workflow로 변환하고 여러 실행 모듈을 통해 작업을 수행
- 문제: 기존 recovery 방식은 실패 시 **LLM 재호출과 재계획에 의존** → 지연 시간·연산 비용 누적, 실패 유형별 일관된 대응 전략 부재
- 본 연구: AI Agentic framework가 **작업 실행 · 실패 판단 · 복구를 통합 orchestration**하는 자율 복구 시스템 제안. LLM은 초기 **workflow 생성**에만 사용

주요 Method


- LLM 기반 초기 **Workflow** 생성 (1회 호출)
- Perception · Manipulation · Verification 모듈 분리 실행
- JSON state/reason 기반 State Monitoring
- 실패 유형 자동 분류 및 Rule-based Recovery



<Figure 1. Conventional LLM-based Recovery vs. Proposed AI Agentic Orchestration>

Method — AI Agentic Orchestration 구조

- ① **Input** : 자연어 명령 인터페이스로 작업 지시 수신
- ② **Planning (초기 1회)** : LLM Workflow Planner가 명령을 detect_object · pick_object · verify_arrival 등 **step 단위 JSON workflow**로 분해. 이후 실행·모니터링·복구 단계에서는 LLM 미호출
- ③ **Workflow Execution** : 각 step을 Remote Executor를 통해 perception · manipulation · verification 모듈로 분리 실행
- ④ **Monitoring** : State Monitor가 step별 실행 결과를 JSON으로 수집해 성공 여부 판단
- ⑤ **Failure Classification** : reason 필드 기반으로 perception(객체 미검출·시점 불량·가림) / manipulation(파지 미끄러짐·충돌) / verification(오배치·검증 불일치) 3종으로 자동 분류
- ⑥ **Autonomous Recovery** : perception → viewpoint 변경 후 재검출, manipulation → grasp angle 변경 후 재파지, verification → 재검출·재파지. 최대 N회 반복




<Figure 2. AI Agentic Framework (Orchestrator) Architecture>

AI Agentic 프레임워크 기반 LLM 로봇 조작 오케스트레이션 시스템

· 실험 환경


- Agentic 프레임워크: **OpenClaw** — LLM 추론, tool 실행, 결과 수집, 다음 행동 결정을 담당하는 orchestration 계층
- 연산 구성: **Jetson Orin SBC**에서 Agentic framework 실행 → **SSH 원격 실행**으로 Local PC의 매니퓰레이터 시뮬레이션 환경 제어
- 대상 장비: 7-DoF 매니퓰레이터, Pick-and-Place 태스크, 물리 시뮬레이션 환경
- 작업 시퀀스: Initial State → Pick → Place(Goal) 3단계
- 비교 조건 3종: (A) recovery 없음 / (B) LLM 기반 recovery / (C) **제안 방식(rule-based recovery)**
- 실험 규모: 동일 환경·동일 작업 집합에서 조건별 **25회 반복 수행**
- 평가 지표: Task Success Rate, Recovery Latency, LLM API 호출 횟수, 실패 유형별 복구 성공률




<Figure 3. Experimental Setup — Jetson Orin SBC and Remote Simulation Environment>

실험 결과 (1) — 복구 전략별 성능 비교


- Task Success Rate: recovery 없음 60.0% → LLM 기반 recovery 76.0% → 제안 rule-based recovery 88.0%
- Recovery Latency: LLM 기반 5.2초 → 제안 방식 0.4초 (약 13배 단축) — 복구 경로에서 네트워크·추론 지연을 제거
- LLM API 호출: LLM 기반 recovery는 task당 3.8회, 제안 방식은 초기 planning 1.0회로 고정 → 실패 횟수와 무관하게 추론 비용이 증가하지 않음



<Figure 4. Task Success Rate>



<Figure 5. Recovery Latency>



<Figure 6. LLM API Calls per Task>

실험 결과 (2) — 실패 유형별 복구 성능

- Perception failure: 18건 발생 / 16건 복구 → 성공률 **88.9%** (평균 시도 1.3회)
- Manipulation failure: 9건 발생 / 8건 복구 → 성공률 **88.9%** (평균 시도 1.4회)
- Verification failure: 5건 발생 / 5건 복구 → 성공률 **100.0%** (평균 시도 1.0회)
- 전체: 32건 중 29건 복구 → 평균 복구 성공률 **90.6%**, 평균 복구 시도 **1.3회**
- 모든 복구가 **LLM 재호출 없이** 수행되었으며, 실패 유형과 복구 동작의 대응 관계를 사전에 규칙으로 고정해 동작을 예측 가능하게 유지

Failure-aware Agentic Orchestration:
LLM은 계획에만, 복구는 결정론적 규칙으로
→ 성공률 60.0% → 88.0%
→ 복구 지연 5.2s → 0.4s, 추가 LLM 호출 0회

Result 4. Failure-type Recovery					
Failure Type	Recovery Strategy	Triggered	Recovered	Success Rate (%)	Avg. Attempts
Perception failure	Change viewpoint + retry detect	18	16	88.9	1.3
Manipulation failure	Alternate grasp angle + retry pick	9	8	88.9	1.4
Verification failure	Re-detect + retry pick	5	5	100.0	1.0
Total	—	32	29	90.6	1.3

<Table 1. Failure-type Recovery Performance>

- **핵심 역량 / 논문 소개**
 - Open-vocabulary 기반 시맨틱 장소 인식 및 환경 모델링 프레임워크
 - Toward Long-Term Memory in Embodied AI: A Knowledge-Grounded 3D Scene Graph Framework
 - DK-SMF: Domain Knowledge-Driven Semantic Modeling Framework for Service Robots
 - LLM-RAG 기반 로봇 Embodiment-aware Affordance 자동 생성 프레임워크
 - Pre-execution Feasibility Checking for Language-Guided Robotic Manipulation via 3D Scene Graph and Object Ontology
 - 시뮬레이터 간 VLA 정책 전이를 위한 성능 갭 정량화 및 효율적 데이터 기반 적응 기법
 - AI Agentic 프레임워크 기반 LLM 로봇 조작 오케스트레이션 시스템
- **진행 중인 연구**
 - VLA 기반 산업용 로봇 조작 정책 학습 및 실환경 적용(26.01~)
 - 기술 역량
 - 연구 실적

VLA 기반 산업용 로봇 조작 정책 학습 및 실환경 적용


직무와 관련 있는 프로젝트 경험

Goal: Sim에서 학습한 VLA 조작 정책을 산업용 매니플레이터 실환경까지 이관

프로젝트 명	기간	참여 인원 수	본인의 역할
[원 과제] 배터리 재활용을 위한 비정형 제조 환경에서 얇은 비강체 부품을 파지 및 조작하기 위한 멀티모달 3D 인지 및 로봇 작업계획	25.09.01~	6	UR3 실환경 플랫폼 구축 & Multi-View Semantic 인식 모듈 설계
[확장] VLA 기반 산업용 로봇 조작 정책 학습 및 실환경 적용 (Doosan M1013)	[기간]	[인원]	Sim2Sim 정책 전이 · 적응 & M1013 3-Layer 기반 실데이터 자동 수집

• **사용 플랫폼:** humanoid → Universal Robots UR3e (원 과제) → **Doosan M1013** (3-Layer 제어 스택을 직접 구현한 기종으로 확장)

<원 과제>



• **Current Progress:** MuJoCo → Isaac Sim Sim2Sim 갭 정량화·적응 완료, M1013 3-Layer 기반 실데이터 300 ep 자동 수집 완료

• **Future Work:** 실데이터 Fine-tuning → M1013 Sim2Real 정책 실행 검증 → 원 과제 Scene Graph 기반 Semantic Grounding 결합

감사합니다.

